

# Méthode cumulative pour la descente de gradient.

---



---

auteur: Denis Rouiller

github: <https://github.com/drrr-deudeu>

## Abstract:

---

Dans ce document, nous détaillons un développement mathématiques et une méthode permettant de corriger/d'actualiser les paramètres d'un modèle linéaire post entraînement/ajustement en déterminant un terme de correction  $\delta\theta$  issue d'un nouvel ensemble de données  $\mathbb{E}_{n+1,n+m}$ . La formule empirique du gain de temps obtenu avec cette méthode de correction est :

$$2n + 4n^2$$

## Introduction:

---

[Bref récap du machine learning, un truc bateau pour introduire]

[l'émergence de l'IA actuelle avec l'augmentation des données et de la puissance de calcul]

[parler de la taille des datasets nécessaires et tjrs de plus en plus groa]

[du temps que l'entraînement peut prendre]

[la prise en compte de nouvelles données permettant de corriger le modèle pour l'obtention de meilleures prédictions] [d'autres idées ?]

Nous détaillons dans ce document un développement mathématiques permettant de corriger les paramètres  $\theta$  du modèle à partir d'un nouvel ensemble de données  $\mathbb{E}_{(n+1,n+m)}$  sans devoir réentraîner le modèle avec l'ensemble de données initiales  $\mathbb{E}_{(1,n+m)}$ , puis nous exposons les résultats de cette nouvelle méthode en comparaison d'un réentraînement classique à partir de l'ensemble de données  $\mathbb{E}_{(1,n+m)} = \mathbb{E}_{(1,n)} + \mathbb{E}_{(n+1,n+m)}$ .

## Méthode:

---

Soit  $n \in \mathbb{N}$ , tel que  $1 < n$

Nous notons  $\mathbb{E}_{(1,n)}$  l'ensemble des données issus de la réunion de  $\mathbb{X}_{(1,n)} = \{x_1, \dots, x_i, \dots, x_n\}$  et  $\mathbb{Y} = \{y_1, \dots, y_i, \dots, y_n\}$ .

Nous avons alors:

$$\forall i \in \mathbb{N} \setminus (1 \leq i \leq n), (x_i, y_i) \in \mathbb{X} \times \mathbb{Y} = \mathbb{E}$$

## Définitions:

$\forall x \in \mathbb{X} = \{x_1, \dots, x_i, \dots, x_n\}$ , on définit  $\bar{x}(n)$  la moyenne des  $n$  éléments  $x_i$  telle que:

$$\bar{x}(n) = \frac{1}{n} \sum_{i=1}^n x_i \quad (a)$$

Notons au passage qu'on a donc:

$$n\bar{x}(n) = \sum_{i=1}^n x_i \quad (b)$$

On définit maintenant  $\sigma_{(n)}(x)$  l'écart-type des  $n$  élément  $x_i$  et la variance  $V_{(n)}(x)$  tels que:

$$\sigma_{(n)}(x) = \sqrt{V_{(n)}(x)} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_{(n)})^2}$$

On peut écrire:

$$V_{(n)}(x) = \frac{1}{n} \sum_{i=1}^n (x_i^2 - 2\bar{x}_{(n)}x_i + \bar{x}_{(n)}^2)$$

$$V_{(n)}(x) = \frac{1}{n} \left( \sum_{i=1}^n x_i^2 - 2\bar{x}_{(n)} \sum_{i=1}^n x_i + \sum_{i=1}^n \bar{x}_{(n)}^2 \right)$$

$$V_{(n)}(x) = \frac{1}{n} \left( \sum_{i=1}^n x_i^2 - 2n\bar{x}_{(n)}\bar{x}_{(n)} + n\bar{x}_{(n)}^2 \right)$$

Donc:

$$V_n(x) = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}_{(n)}^2 \quad (c)$$

## Développement

Soit maintenant  $m \in \mathbb{N}$ , tel que  $1 < m$ .

Soit l'ensemble  $\mathbb{X}_{(n+m)} = \{x_1, \dots, x_i, \dots, x_n, x_{n+1}, \dots, x_{n+m}\}$ . Alors la moyenne des  $n + m$  éléments  $x_i$  de  $\mathbb{X}_{(n+m)}$ , notée  $\bar{x}(n + m)$ :

$$\bar{x}_{(n+m)} = \frac{1}{n+m} \sum_{i=1}^{n+m} x_i$$

$$\bar{x}_{(n+m)} = \frac{1}{n+m} \left( \sum_{i=1}^n x_i + \sum_{i=n+1}^m x_i \right)$$

en utilisant l'équation (b) on en déduit:

$$\bar{x}_{(n+m)} = \frac{1}{n+m} (n\bar{x}_{(n)} + m\bar{x}_{(m)})$$

Calculons maintenant la variance de  $\mathbb{X}_{(n+m)}$

$$V_{(n+m)}(x) = \frac{1}{n+m} \sum_{i=1}^{n+m} (x_i - \bar{x})^2$$

$$V_{(n+m)}(x) = \frac{1}{n+m} \sum_{i=1}^{n+m} x_i^2 - \bar{x}_{(n+m)}^2$$

$$V_{(n+m)}(x) = \frac{1}{n+m} \left( \sum_{i=1}^n x_i^2 + \sum_{i=n+1}^m x_i^2 \right) - \bar{x}_{(n+m)}^2$$

On définit la normalisation de l'ensemble  $\mathbb{X}_{(n)}$ , la transformation faisant passer  $x_i$  à  $X_i$  comme suit, dans l'ensemble  $\mathbb{X}_{(n)}$ :

$$X_{(n)i} = \frac{x_i - \bar{x}}{\sigma_{(n)}(x)} \quad (d)$$

Notons au passage les résultats suivants:

$$\bar{X}_{(n)} = \frac{1}{n\sigma_{(n)}(x)} \sum_{i=1}^n (x_i - \bar{x}) = 0 \quad (e)$$

$$\sum_{i=1}^n X_i^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{\sigma(x)^2} = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} = \frac{n}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x})^2 = n \quad (f)$$

## Application dans le cas d'une droite de régression linéaire:

Nous nous intéressons ici à l'application de la méthode de la descente de gradient à une droite de régression linéaire telle que:

$$\hat{Y} = F(X) = \theta_0 + \theta_1 X \quad (g)$$

La méthode consiste à s'approcher itérativement des valeurs optimales des  $\theta$  i.e. celles pour lesquelles le coût est minimum. Les équations proposées pour résoudre ce problème ne sont valables qu'avec des données normalisées: Chaque itération donne des nouvelles valeurs des  $\theta$ :

$$\theta_0 \leftarrow \theta_0 - d\theta_0$$

$$\theta_1 \leftarrow \theta_1 - d\theta_1$$

Avec:

$$d\theta_0 = \frac{\alpha}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i) \text{ et } d\theta_1 = \frac{\alpha}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i) X_i$$

avec  $\alpha$  définit comme étant le "learning~ rate",  $\hat{Y}_i$  la valeur prédite en  $X_i$  et  $Y_i$  la valeur normalisée de  $y_i$ .

On peut donc écrire:

$$\frac{d\theta_0}{\alpha} = \frac{1}{n} \sum_{i=1}^n \hat{Y}_i - \bar{Y}(n) = \frac{1}{n} \sum_{i=1}^n (\theta_0 + \theta_1 X_i) - \bar{Y}(n)$$

En appliquant (e):

$$\frac{d\theta_0}{\alpha} = \theta_0$$

On a donc à chaque itération:

$$\theta_0 \leftarrow \theta_0 - \alpha \theta_0$$

De même:

$$\frac{d\theta_1}{\alpha} = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i) X_i$$

$$\frac{d\theta_1}{\alpha} = \frac{1}{n} \sum_{i=1}^n (\theta_0 + \theta_1 X_i - Y_i) X_i$$

$$\frac{d\theta_1}{\alpha} = \frac{\theta_0}{n} \sum_{i=1}^n X_i + \frac{\theta_1}{n} \sum_{i=1}^n X_i^2 - \frac{1}{n} \sum_{i=1}^n X_i Y_i$$

Mais d'après (e), on a  $\bar{X}(n) = 0$ , d'où :

$$\frac{d\theta_1}{\alpha} = \frac{\theta_1}{n} \sum_{i=1}^n X_i^2 - \frac{1}{n} \sum_{i=1}^n X_i Y_i$$

et en appliquant (f), on trouve:

$$\frac{d\theta_1}{\alpha} = \theta_1 - \frac{1}{n} \sum_{i=1}^n X_i Y_i$$

Donc,  $\theta_1 \leftarrow \theta_1 - \alpha(\theta_1 - \frac{1}{n} \sum_{i=1}^n X_i Y_i)$

Notons, que nous avons:

$$\begin{aligned} \sum_{i=1}^n X_i Y_i &= \sum_{i=1}^n \frac{(x_i - \bar{x}(n))(y_i - \bar{y}(n))}{\sigma(n)(x)\sigma(n)(y)} = \frac{1}{\sigma(n)(x)\sigma(n)(y)} \sum_{i=1}^n (x_i y_i - x_i \bar{y}(n) - \bar{x}(n) y_i + \bar{x}(n) \bar{y}(n)) \\ &\Rightarrow \sum_{i=1}^n X_i Y_i = \frac{1}{\sigma(n)(x)\sigma(n)(y)} (\sum_{i=1}^n x_i y_i - n \bar{x}(n) \bar{y}(n)) \quad (h) \end{aligned}$$

Pour l'ensemble (n+m) on aura :

$$\theta_0 \leftarrow \theta_0 - \alpha \theta_0$$

$$\theta_1 \leftarrow \theta_1 - \alpha(\theta_1 - \frac{1}{n+m} \sum_{i=1}^{n+m} X_i Y_i)$$

Qui peut encore s'écrire:

$$\theta_1 \leftarrow \theta_1 - \alpha \left[ \theta_1 - \frac{1}{(n+m)\sigma_{(n+m)}(x)\sigma_{(n+m)}(y)} \left( \sum_{i=1}^{n+m} x_i y_i - (n+m)\bar{x}_{(n+m)}\bar{y}_{(n+m)} \right) \right]$$

Avec  $\sigma_{(n+m)}(x) = \sqrt{V_{(n+m)}(x)}$  et  $\sigma_{(n+m)}(y) = \sqrt{V_{(n+m)}(y)}$

Enfin la dénormalisation des  $\theta$ :

D'après (d) et (f), on a:

$$\frac{\hat{y}_i - \bar{y}(n)}{\sigma_{(n)}(y)} = \theta_0 - \theta_1 \frac{x_i - \bar{x}(n)}{\sigma_{(n)}(x)}$$

$$\hat{y}_i = \sigma_{(n)}(y) \left( \theta_0 - \frac{\theta_1}{\sigma_{(n)}(x)} \bar{x}(n) \right) + \bar{y}(n) + \theta_1 \frac{\sigma_{(n)}(y)}{\sigma_{(n)}(x)} x_i$$

D'où, par identification:

$$THETA(0) = \sigma_{(n)}(y) \left( \theta_0 - \frac{\theta_1}{\sigma_{(n)}(x)} \bar{x}(n) \right) + \bar{y}(n)$$

$$THETA(1) = \theta_1 \frac{\sigma_{(n)}(y)}{\sigma_{(n)}(x)}$$

## Observation:

Le calcul des  $\theta$  pour un ensemble  $n + m$ , ne nécessitent que la connaissance des grandeurs suivantes:

- Le cardinal  $n$ , de notre ancien ensemble
- Les  $\theta$  normalisées sur l'ensemble  $X_{(n)}$
- Les grandeurs:  $\bar{x}(n)$ ,  $\bar{y}(n)$ ,  $\sum_{i=1}^n x_i^2$ ,  $\sum_{i=1}^n y_i^2$ ,  $\sum_{i=1}^n x_i y_i$
- l'ensemble des  $X_i$  et des  $Y_i$  appartenant aux ensembles

## Cas particulier:

Avec l'ajout d'une seule valeur  $x_{n+1}$ , on aura:

$$\bar{x}(n+1) = \frac{1}{n+1} (n\bar{x}(n) + x_{n+1})$$

$$V_{(n+1)}(x) = \frac{1}{n+m} \left( \sum_{i=1}^n x_i^2 + x_{n+1}^2 \right) - \bar{x}_{(n+m)}^2$$

$$\sigma_{(n+1)}(x) = \sqrt{V_{(n+1)}}(x)$$

$$X_{n+1} = \frac{x_{n+1} - \bar{x}_{(n+1)}}{\sigma_{(n+1)}(x)}$$

## Méthodologie:

Analytique

## Résultats:

---

## Conclusion:

---